

Лабораторна робота 5

Порівняння двох незалежних вибірок

Мета роботи

Мета роботи – познайомитися з основами перевірки статистичних гіпотез та порівняння вибірок, набути практичних навичок застосування статистичних тестів для порівняння двох незалежних вибірок.

Постановка завдання

Задано дві практичні задачі (див. задачі для свого індивідуального варіанту). В одній із задач мають місце залежні вибірки, в іншій – незалежні. У цій лабораторній роботі потрібно працювати лише із незалежними вибірками, а в попередній – із залежними.

Потрібно визначити, в якій із задач мають місце незалежні вибірки і для них виконати таке:

- перевірити нормальність розподілу кожної вибірки будь-яким методом, вивченим в попередній лабораторній роботі;
- за кожною вибіркою обчислити середнє значення та медіану разом з 95% довірчим інтервалом для них; зробити висновок про близькість центральних тенденцій для обох вибірок як попередню оцінку перед застосуванням формальних критеріїв;
- застосувати двовибірковий t-критерій для порівняння середніх і зробити висновки на його основі; **не забудьте**, що попередньо потрібно перевірити рівність дисперсій обох вибірок (наприклад, F-критерієм, критерієм Бартлєта або Левене; серед них перевагу має критерій Левене, оскільки він більш стійкий до відхилень від нормального розподілу); якщо дисперсії обох вибірок збігаються, тоді слід застосувати точний двовибірковий t-критерій, інакше – з правкою Уелча;
- застосувати заданий індивідуальним варіантом ранговий критерій зсуву і зробити висновки на його основі; якщо ваш порядковий номер у списку групи є парним, тоді потрібно застосувати критерій суми рангів Вілкоксона, інакше – Манна–Уїтні;
- дати відповідь на запитання із задачі, пояснити можливі розбіжності в критеріях та умови їх застосування.

Для виконання цього завдання потрібно створити невеликий додаток будь-якою мовою програмування, який повинен дозволити:

- завантажувати дані двох вибірок з текстового файлу; передбачається, що у файлі два стовпці: перший містить елементи вибірки, другий – мітку, яка вказує на те, з якої вибірки цей елемент (наприклад, 0/1, 1/2 або x/y).
- розраховувати для кожної вибірки статистичні характеристики (середнє, медіана, середньоквадратичне відхилення, коефіцієнти асиметрії та ексцесу) разом із довірчими інтервалами;
- перевіряти нормальність розподілу кожної вибірки будь-яким методом, вивченим раніше;
- застосовувати двовибірковий t-критерій (точний або з правкою Уелча залежно від результатів перевірки рівності дисперсій) і виводити користувачу статистику критерію, критичне значення або p-значення та висновок;
- застосовувати ранговий критерій зсуву і виводити користувачу статистику критерію, критичне значення або p-значення та висновок.

Особливі вимоги:

- двовибірковий t-критерій (точний та з правкою Уелча), ранговий критерій зсуву та функцію розрахунку рангів потрібно реалізувати самостійно;

- для інших задач (наприклад, розрахунку статистичних характеристики, квантилів, значень функції розподілу для р-значення, перевірки на нормальність, перевірки рівності дисперсії) можна використовувати вбудовані функції;
- передбачити обробку випадку, коли обидві вибірки повністю збігаються;
- програма повинна виводити результати у табличній формі, придатній для копіювання у звіт;
- програма має працювати з різними файлами та вибірками різного обсягу.

Звіт. За результатами виконання лабораторної роботи оформити звіт у MS Word. Звіт має містити такі розділи:

1. Титульний аркуш.
2. Власний програмний код.
3. Результати аналізу (пояснити, чому вибірки вважаються незалежними; навести результати перевірки обох вибірок на нормальність; подати середні значення та медіани з 95% довірчими інтервалами для обох вибірок та їх аналіз; навести результати застосованих критеріїв у вигляді статистики, квантиля/р-значення, висновку; порівняти результати t-критерію та рангового критерію: чи узгоджуються вони, і який з них краще застосовувати у даному випадку; відповісти на запитання із задачі).
4. Висновки (які нові знання та практичні навички отримано; пояснити, що таке незалежні вибірки; вказати, які критерії є параметричними, а які – непараметричними, пояснити, коли на практиці варто віддавати перевагу тим чи іншим критеріям).

Текст звіту оформити, використовуючи такі налаштування: шрифт Times New Roman, кегль 14 pt, абзацний відступ 1.25 см, міжрядковий інтервал 1.5, інтервал до та після абзацу 0 pt.

Захист. Виконану роботу (програму та звіт) необхідно захистити на лабораторному занятті. Під час захисту потрібно пояснювати і відтворювати алгоритм реалізованих критеріїв, демонструвати роботу програми на інших наборах даних, інтерпретувати результати.

Альтернативне завдання

Можна провести порівняння двох незалежних вибірок із задачі в MS Excel (див. практики 5 та 7 в [1]). При цьому можна не перевіряти нормальність розподілу вибірок, але потрібно розуміти, що на практиці t-критерій застосовують у випадку, коли обидві вибірки мають нормальний розподіл.

У цьому випадку кількість балів за лабораторну роботу буде знижена.

Рекомендована література

1. Методичні вказівки до виконання практичних робіт із дисципліни «Математична статистика та обробка геологічної інформації» / Укладачі Мацуга О.М., Ємел'яненко Т.Г. Дніпро: РВВ ДНУ, 2019. 64 с.
2. Приставка П.О., Мацуга О.М. Аналіз даних: Навч. посіб. / затв. МОН України. Д.: РВВ ДНУ, 2008. 92 с.

Індивідуальні варіанти

Номер індивідуального варіанту – це порядковий номер студента у списку групи.