

Лабораторна робота 6

Аналіз даних з використанням Python

Мета роботи

Мета роботи – вивчити можливості бібліотек Python для проведення первинного статистичного аналізу даних та порівняння двох вибірок.

Постановка завдання

Задано практичну задачу на порівняння вибірок (див. свій індивідуальний варіант).

Розв'яжіть цю задачу, використовуючи мову Python та бібліотеки pandas, numpy, scipy.stats, matplotlib/seaborn, за такою схемою:

1. Визначте, залежні чи незалежні вибірки задано у задачі.
2. Завантажте вибірки, які потрібно порівняти, з текстового файлу.
3. Якщо вибірки залежні:
 - сформууйте вибірку різниць;
 - перевірте, чи нормально розподілена вибірка різниць;
 - розрахуйте та проаналізуйте для вибірки різниць середнє, медіану й середньоквадратичне відхилення разом із 95% довірчими інтервалами;
 - візуалізуйте вибірки за допомогою box plot та/або violin plot; проаналізуйте отримані графіки, звертаючи увагу на положення центральних тенденцій і асиметрію розподілу;
 - застосуйте парний t-критерій для порівняння середніх і зробіть висновки на його основі;
 - застосуйте критерій знакових рангів Вілкоксона і зробіть висновки на його основі.
4. Якщо вибірки незалежні:
 - для кожної вибірки перевірте, чи нормально вона розподілена;
 - для кожної вибірки розрахуйте та проаналізуйте середнє, медіану й середньоквадратичне відхилення разом із 95% довірчими інтервалами;
 - візуалізуйте вибірки за допомогою box plot та/або violin plot; проаналізуйте отримані графіки, звертаючи увагу на положення центральних тенденцій і асиметрію розподілу;
 - застосуйте двовибірковий t-критерій для порівняння середніх та зробіть висновки на його основі; **не забудьте** попередньо перевірити рівність дисперсій обох вибірок (наприклад, критерієм Левене – він більш стійкий до відхилень від нормального розподілу); якщо дисперсії збігаються, слід застосувати точний двовибірковий t-критерій, інакше – з правкою Уелча;
 - застосуйте критерій суми рангів Вілкоксона і зробіть висновки на його основі.
5. Дайте відповідь на запитання із задачі та поясніть можливі розбіжності в критеріях і умови їх застосування.

В пункті про перевірку на нормальність **скористайтесь чотирма методами**:

 - візуальний аналіз на основі гістограм;
 - візуальний аналіз на основі імовірнісного паперу (Q-Q plot);
 - статистичні тести, які перевіряють рівність нулю коефіцієнтів асиметрії та ексцесу (виведіть користувачу результати тестів та значення самих коефіцієнтів);
 - статистичний тест Шапіро-Уїлка

Надайте висновки про нормальність розподілу за кожним методом. Для ухвалення остаточного загального рішення про нормальність розподілу врахуйте наступне: для вибірок розміром 20-50 елементів, висновки тесту Шапіро-Уїлка є найважливішими, оскільки цей тест є найбільш потужним для таких розмірів. Однак, завжди потрібно підкріплювати його висновки візуальним аналізом ймовірнісного паперу.

Звіт. В якості звіту може виступати Jupyter Notebook який має містити такі елементи:

1. Заголовок: текстова чарунка з назвою роботи та ім'ям студента.
2. Вступ: текстова чарунка з коротким описом задачі.
3. Код: чарунки з кодом для виконання завдання.
4. Аналіз та висновки: текстові чарунки після графіків і таблиць із інтерпретацією результатів + в кінці текстова чарунка із загальним висновком.

Захист. Виконану роботу необхідно захистити на лабораторному занятті. Під час захисту потрібно пояснювати, що роблять використані функції, та надавати інтерпретацію одержаним результатам.

Рекомендована література

1. Lutz M. Learning Python. O'Reilly, 2013. 1643 p.
2. McKinney W. Python for Data Analysis. O'Reilly, 2022. 579 p.
3. VanderPlas J. Python Data Science Handbook. O'Reilly, 2017. 546 p.

Індивідуальні варіанти

Кожен студент повинен розв'язати **одну задачу** згідно зі своїм індивідуальним варіантом. Номер задачі визначається так:

1. Візьміть свій порядковий номер у журналі групи.
2. Поділіть його на 5.
3. Залишок від ділення буде номером задачі, яку Ви маєте розв'язати (0, 1, 2, 3 або 4).

Приклади:

1. Якщо у журналі Ви записані під номером 7, тоді залишок від ділення 7 на 5 становить 2 $\rightarrow$ Ви розв'яжете задачу 2.
2. Якщо Ваш номер 15, тоді залишок дорівнює 0 $\rightarrow$ Ви розв'яжете задачу 0.

Задача 0. У файлі readingspeed.txt міститься інформація щодо швидкості читання у дітей залежно від методики, за якою їх навчали (DRA – direct reading activities, SC – standart curriculum). Потрібно перевірити, чи різняться швидкість читання у разі навчання за цими методиками.

Задача 1. Для 61 великого міста Англії та Уельсу відома середня річна смертність на 100 тис. населення (за даними 1958-1964 років). Додатково міста поділено на південні та північні. Дані містяться у файлі water.txt (стовпці location, mortality). Потрібно перевірити, чи різняться середня смертність на півночі та півдні країни.

Задача 2. Для 61 великого міста Англії та Уельсу відома концентрація калію у воді (в частинах на мільйон). Чим вища концентрація калію, тим жорсткіша вода. Додатково міста поділено на південні та північні. Дані містяться у файлі water.txt (стовпці location, hardness). Потрібно перевірити, чи різняться жорсткість води у північних та південних містах.

Задача 3. У рамках дослідження ефективності препарату «метилфенидат» 24 пацієнти із синдромом дефіциту уваги та гіперактивності протягом тижня приймали або метилфенидат, або плацебо. Наприкінці тижня кожен пацієнт проходив тест на здатність до пригнічення імпульсивних поведінкових реакцій. На другому етапі плацебо та препарат мінялися, і після тижневого курсу кожний піддослідний проходив другий тест. Результати першого та другого тестів містяться у файлі ADHD.txt. Потрібно оцінити ефект від застосування препарату.

Задача 4. На замовлення власника заводу група експертів провела оцінку вин «Шардоне» та «Каберне Совіньон», що випускаються цим заводом. Оцінка проводилася за 20 бальною шкалою (чим вищий бал, тим краще вино), результати подано у файлі wines.txt. Чи можна на основі цих оцінок вважати одне з вин кращим?

Рекомендації по застосуванню бібліотек Python

У процесі виконання лабораторної роботи можна використовувати наступні функції та методи з бібліотек для мови Python.

Для завантаження даних з текстового файлу до **DataFrame** – функція `pandas.read_csv`

Для одержання оцінок основних статистичних характеристик

метод `describe` об'єкту **DataFrame**

або методи `mean`, `median`, `std`, `min`, `max` об'єкту **DataFrame**

або аналогічні функції з бібліотеки **NumPy**

Для обчислення квантилю розподілу (потрібний в процесі побудови довірчих інтервалів для параметрів) слід використовувати функції модуля `scipy.stats`

`t.ppf(q, df)` – квантиль розподілу Стюдента порядку q з кількістю ступенів вільності df

`norm.ppf(q)` – квантиль стандартного нормального розподілу порядку q

`chi2.ppf(q, df)` – квантиль χ^2 -розподілу порядку q з кількістю ступенів вільності df

Для оцінювання коефіцієнтів асиметрії, ексцесу і їх перевірки на рівність нулю знадобляться функції із модуля `scipy.stats`:

`skew` – повертає оцінку коефіцієнта асиметрії

`skewtest` – перевіряє рівність коефіцієнта асиметрії нулю

`kurtosis` – повертає оцінку коефіцієнта ексцесу

`kurtosistest` – перевіряє рівність коефіцієнта ексцесу нулю

також може бути використана функція

`normaltest` – реалізує критерій, який перевіряє одночасну рівність нулю коефіцієнтів асиметрії та ексцесу

Для побудови гістограми

метод `hist` об'єкту **Series**

або функцію `hist` із `matplotlib.pyplot`

або функцію `histplot` з бібліотеки **seaborn**

Для ідентифікації нормального розподілу за ймовірнісним папером – функція `probplot` із модуля `scipy.stats`

Для перевірки вірогідності нормального розподілу за критерієм Шапіро–Уїлка знадобиться функція `shapiro` із модуля `scipy.stats`.

Для побудови графіків **boxplot** та **violinplot** можна використати функції

`boxplot` з бібліотеки **seaborn** або `matplotlib.pyplot`

`violinplot` з бібліотеки **seaborn**

Для порівняння вибірок за статистичними тестами знадобляться такі функції з модуля `scipy.stats`:

`ttest_ind` – двохвибірковий t критерій перевірки рівності середніх (для незалежних вибірок)

`ttest_rel` – парний t критерій перевірки рівності середніх (для залежних вибірок)

`bartlett` або `levene` – критерії перевірки рівності дисперсій (не обов'язково двох, а й більшої кількості; F критерій для перевірки рівності двох дисперсій не реалізований)

`wilcoxon` – критерій знакових рангів Вілкоксона (для залежних вибірок)

ranksums – критерій суми рангів Вілкоксона (для незалежних вибірок)

У переліку також є функція *mannwhitneyu* – вона реалізує критерій Манна–Уїтні (для незалежних вибірок), у її аргументах можна визначити вид альтернативної гіпотези (*alternative*= 'less', 'two-sided', or 'greater', по замовчуванню 'less').

Також слід відмітити функцію

ttest_1samp – одновибірковий *t* критерій перевірки рівності середнього генеральної сукупності заданій константі